

Universiteti i Prishtinës “Hasan Prishtina”

Fakulteti Inxhinierisë Elektrike dhe Kompjuterike



Dokumentim teknik i projektit

Lënda: Big Data

Titulli i projektit: NoSQL, Big Data & Network Analysis

Prof. Dr. Vigan RAÇA PhD Cand. Rafet DURIQI	1. Amela Syla	amela.syla@student.uni-pr.edu
	2. Elsa Krasniqi	elsa.krasniqi12@student.uni-pr.edu
	3. Elona Kuqi	elona.kuqi@student.uni-pr.edu
	4. Fahrije Gjokiqi	fahrije.gjokiqi@student.uni-pr.edu
	5. Florjetë Kuka	florjete.kuka@student.uni-pr.edu

Prishtinë, 2025/26

Përmbajtja

I. Hyrje.....	2
II. Qëllimi i punimit.....	3
III. Pjesa kryesore.....	3
III.1 Konfigurimi i Mjedisit dhe Teknologjitë e Përdorura.....	3
III.2 NoSQL Data.....	4
III.2.1 Migrimi i skenës dhe të dhënave.....	4
III.2.2 Shkrimi i NoSQL query-ve.....	4
III.3 Big Data (Apache Spark / Hadoop).....	4
III.3.1 Konfigurimi i Mjedisit.....	4
III.3.2 Importimi i Dataset-eve.....	5
III.3.5 Query-t SparkSQL të Adaptuara nga XPath/XQuery.....	6
III.4 Importimi i datasetit të ri.....	7
III.4.1. Qëllimi i punës.....	7
III.3.2. Dataset-i i përdorur.....	7
III.4.3. Teknologjia e përdorur.....	8
III.4.4. Importimi dhe përgatitja e të dhënave.....	8
III.4.5. Analiza e të dhënave.....	8
III.4.6. Analiza e avancuar.....	10
III.4.7. Vizualizimi i të dhënave.....	10
III.4.7.2 Top 5 produktet energjetike.....	11
III.5 Network Analysis.....	12
III.5.1. Vizualizimi i Rrjetit Social (Social Network Visualization).....	12
III.5.2. Degree Centrality.....	13
III.5.3. Betweenness Centrality.....	14
III.5.3. Closeness Centrality.....	15
IV. Konkluzione.....	16

I. Hyrje

Ky projekt trajton konceptet e Big Data përmes migrimit dhe analizës së të dhënave në teknologji të ndryshme. Fillimisht, të dhënat relacionale nga SQL janë migruar në MongoDB duke transformuar tabelat në dokumente NoSQL. Më pas, dataset-et janë përpunuar në Apache Spark për analiza të shpërndara dhe ekzekutim të SparkSQL query-ve. Gjithashtu, është realizuar analiza e rrjeteve me

teori të grafeve dhe metrika si Degree, Closeness dhe Betweenness Centrality. Qëllimi kryesor është krahasimi i qasjeve relacionale, NoSQL dhe Big Data në trajtimin dhe analizën e të dhënave.

II. Qëllimi i punimit

Qëllimi i këtij projekti është aplikimi praktik i teknologjive të avancuara të Big Data duke u ndërtuar mbi punën e fazave të mëparshme. Konkretisht, projekti synon:

- **Migrimin** e skemës dhe të dhënave nga baza relacionale e Fazës 1 në platformën NoSQL (MongoDB), duke adaptuar query-t SQL në formatin NoSQL
- **Procesimin** e dataset-eve në Apache Spark dhe riimplementimin e query-ve XML/XPath të Fazës 2 si SparkSQL
- **Analizën e rrjeteve** duke aplikuar teorinë e grafeve dhe llogaritjen e metrikave të Social Network Analysis (Betweenness, Closeness dhe Degree Centrality)
- **Krahasimin** e teknologjive relacionale, NoSQL dhe Big Data në aspektin e sintaksës, performancës dhe fleksibilitetit.

III. Pjesa kryesore

III.1 Konfigurimi i Mjedisit dhe Teknologjitë e Përdorura

III.1.1 Mjedisi i Punës

- MongoDB
- MongoDB Compass
- Azure Databricks
- Apache Spark 4.0
- SparkSQL
- Python
- ORA
- DBFS

III.1.2 Dataset-et e Përdorura

- WorldBank_dataset ([WorldBank](#))
- fuelPrices ([Kaggle](#))
- world-oil-data.csv ([Kapsarc](#))

III.2 NoSQL Data

III.2.1 Migrimi i skenës dhe të dhënave

Në këtë fazë është realizuar migrimi i të dhënave nga baza relacionale SQL në databazën NoSQL MongoDB. Struktura tabelare e bazës relacionale është transformuar në koleksione dhe dokumente JSON, duke përshtatur modelin e të dhënave për Big Data. Gjatë migrimit janë përfshirë tabelat

kryesore të përdorura në query-t e Fazës 1 dhe është verifikuar integriteti i të dhënave pas importimit në MongoDB. Gjithashtu, çdo rekord nga tabela SQL është ruajtur si dokument individual në collection përkatëse.

III.2.2 Shkrimi i NoSQL query-ve

Query 1 - Krahësimi i Rritjes GDP me Çmimin e Karburantit

Kryen një join ndërmjet dy koleksioneve: të dhënat e GDP growth nga WorldBank_dataset dhe çmimet e karburantit nga fuelPrices, duke i bashkuar sipas vendit dhe vitit. Qëllimi është të shihet nëse ekziston lidhje ndërmjet rritjes ekonomike dhe çmimit të karburantit.

SQL	MongoDB
<pre>SELECT w.Country, w.Year,w.IndicatorValue AS GDPGrowth, AVG(f.Price) AS AvgFuelPrice FROM wdi_data w JOIN fuelPrices f ON w.Country = f.Country AND w.Year = YEAR(f.Date) WHERE w.IndicatorName = 'GDP growth (annual %)' AND w.IndicatorValue IS NOT NULL GROUP BY w.Country, w.Year ORDER BY w.Country, w.Yearm LIMIT 20;</pre>	<pre>db.WorldBank_dataset.aggregate([{ \$match: {IndicatorName: "GDP growth (annual %)",IndicatorValue: { \$ne: null }}},{ \$lookup: {from: "fuelPrices",let: {country: "\$Country",year:"\$Year"}, pipeline: [{ \$addFields: {FuelYear: {\$year: {\$toDate: "\$Date"}}}}, { \$match: { \$expr: { \$and: [{ \$eq: ["\$Country","\$\$country"] }, { \$eq: ["\$FuelYear", "\$\$year"] }] }, FuelType:"Petrol_Price_USD_per_Liter"} }},as: "FuelData" }},{ \$match: { FuelData: { \$ne: [] } } } { \$project: { _id: 0,CountryName: "\$Country",Year: "\$Year",GDPGrowth:"\$IndicatorValue",AvgFuelPrice: { \$avg: "\$FuelData.Price" } }},{ \$sort: { CountryName: 1, Year: 1 } }, { \$limit: 20 }])</pre>

III.3 Big Data (Apache Spark / Hadoop)

III.3.1 Konfigurimi i Mjedisit

Për implementimin e pjesës Big Data u përdor Azure Databricks si platformë për ekzekutimin e Apache Spark dhe SparkSQL.

U krijua një cluster me emrin **phase3-cluster**, i cili u përdor për importimin, përpunimin dhe ekzekutimin e query-ve mbi dataset-et.

Mjedisi përfshinte:

- Apache Spark 4.0

- SparkSQL
- Azure Databricks Runtime 17.3 LTS
- Python Notebooks
- DBFS (Databricks File System)

State	Name	Policy	Runtime	Active ...	Active c...	Active D...	Source	Creator	Notebo...
●	phase3-cluster	-	17.3	16 GB	4 cores	1.5	UI	florjete.kuka	1

Figura 1 – Konfigurimi i cluster-it phase3-cluster në Azure Databricks për ekzekutimin e Apache Spark dhe SparkSQL.

III.3.2 Importimi i Dataset-eve

World_bank_dataset dhe fuel_price vijnë nga Faza 1, ndërsa worldbank_dwh përfaqëson të dhënat e Data Warehouse/XML nga Faza 2.

Pas importimit u verifikuan skema, tipat e kolonave dhe numri i rreshtave për secilin dataset duke përdorur funksionet show(), printSchema() dhe count().

```

▶ 08:41 PM (6s) 17
worldbank_df.show(5)

```

Country	CountryCode	Year	IndicatorName	IndicatorValue	RowId
Afghanistan	AFG	2015	GDP growth (annua...	1.451314661	1
Afghanistan	AFG	2015	GDP per capita (c...	565.5697304	2
Afghanistan	AFG	2015	Inflation, consum...	-0.661709165	3
Afghanistan	AFG	2015	Urban population ...	24.46491184	4
Afghanistan	AFG	2015	Trade (% of GDP)	NULL	5

only showing top 5 rows

Figura 2 – Verifikimi i importimit të dataset-it WorldBank_dataset në Apache Spark duke përdorur funksionin show(5).


Për optimizimin e procesimit në Apache Spark, dataset-et e importuara u konvertuan në formatin Parquet. Ky format u zgjodh për shkak të kompresimit efikas dhe performancës më të mirë gjatë leximit dhe ekzekutimit të query-ve në mjedis Big Data.

III.3.5 Query-t SparkSQL të Adaptuara nga XQuery

Në këtë pjesë u implementuan dy query SparkSQL të bazuara në query-t XQuery të realizuara në Fazën 2. Qëllimi ishte demonstrimi i mënyrës se si e njëjta logjikë analitike mund të implementohet në Apache Spark duke përdorur SparkSQL.

Query 1 – Mesatarja e vlerave të indikatorëve për Kosovën

Query-ja e parë llogarit mesataren e vlerave të indikatorëve për Kosovën. Në Fazën 2, kjo analizë u realizua mbi dokumentet XML duke përdorur XPath/XQuery, ndërsa në Fazën 3 u implementua në SparkSQL përmes funksioneve **WHERE**, **AVG** dhe **GROUP BY**. Rezultati i marrë demonstroi se e njëjta logjikë analitike mund të zbatohet në Apache Spark duke ruajtur funksionalitetin e query-t original.



```
spark.sql("""
SELECT
  CountryName,
  AVG(CAST(IndicatorValue AS DOUBLE)) AS avg_value
FROM worldbank_xml
WHERE CountryName = 'Kosovo'
GROUP BY CountryName
""").show()
```

(2) Spark Jobs

CountryName	avg_value
Kosovo	713.6297971428573

Figura 3 – Query 1 dhe rezultati i ekzekutimit

Query 2 – Renditja e shteteve sipas GDP per Capita

Query-ja e dytë realizon renditjen e shteteve sipas vlerës së indikatorit GDP per capita. Në Fazën 2, filtrimi dhe renditja e të dhënave realizohej përmes XPath/XQuery mbi strukturën XML, ndërsa në SparkSQL u përdorën klauzolat **WHERE**, **ORDER BY** dhe **LIMIT**. Rezultatet tregojnë shtetet me GDP per capita më të lartë dhe konfirmojnë ekuivalencën ndërmjet implementimit XML dhe SparkSQL.

```
spark.sql("""
SELECT
    CountryName,
    Year,
    CAST(IndicatorValue AS DOUBLE) AS gdp_per_capita
FROM worldbank_xml
WHERE IndicatorName = 'GDP per capita (current US$)'
AND IndicatorValue IS NOT NULL
ORDER BY gdp_per_capita DESC
LIMIT 10
""").show()
```

► (1) Spark Jobs

CountryName	Year	gdp_per_capita
Monaco	2024	288001.4334
Monaco	2023	256799.7886
Monaco	2022	226052.0019
Monaco	2021	223823.364
Liechtenstein	2023	206780.5904
Liechtenstein	2021	201944.8303
Monaco	2019	193746.7856
Monaco	2018	188298.3157
Liechtenstein	2022	188055.0032
Monaco	2020	176891.8865

Figura 4 – Query 2 dhe rezultati i ekzekutimit

III.4 Importimi i datasetit të ri

III.4.1. Qëllimi i punës

Qëllimi i kësaj pjese të projektit është demonstrimi i përdorimit të Apache Spark për importimin dhe analizën e një dataset-i të madh. Analiza përfshin verifikimin e të dhënave, statistika përshkruese, agregime dhe SparkSQL.

III.3.2. Dataset-i i përdorur

Në këtë projekt është përdorur dataset-i “world-oil-data.csv”, i cili përmban të dhëna mbi energjinë në nivel global.

Karakteristikat e dataset-it:

- Numri i rreshtave: 504,926
- Madhësia e file: 29.73 MB

```
print("=== FIRST ROWS ===")
big_df.show(5)
```

Year	Country	Energy Product Name	Flow Breakdown	Unit Of Measure	Value	Assessment Code
6/1/2010	Kuwait	Liquefied petrole...	Exports	KBD	129.0	3
6/1/2010	Kuwait	Liquefied petrole...	Exports	KTONS	333.620697	3
6/1/2010	Kuwait	Liquefied petrole...	Imports	KL	0.0	3
7/1/2010	Kuwait	Liquefied petrole... IProducts transfe...		CONVBBL	11600.0	3
7/1/2010	Kuwait	Liquefied petrole... IProducts transfe...		KBD	0.0	3

only showing top 5 rows

Figura 5 – Verifikimi i importimit të dataset-it world-oil-data.csv në Apache Spark.

III.4.3. Importimi dhe përgatitja e të dhënave

Dataset-i u importua në Apache Spark dhe u verifikua përmes funksioneve show(), printSchema() dhe count(). Këto funksione u përdorën për të kontrolluar strukturën e kolonave dhe numrin total të rreshtave.

```

• print("=== SCHEMA ===")
  big_df.printSchema()

  print("=== ROW COUNT ===")
  print(big_df.count())

```

```

=== SCHEMA ===
root
|-- Year: string (nullable = true)
|-- Country: string (nullable = true)
|-- Energy Product Name: string (nullable = true)
|-- Flow Breakdown: string (nullable = true)
|-- Unit Of Measure: string (nullable = true)
|-- Value: double (nullable = true)
|-- Assessment Code: long (nullable = true)

=== ROW COUNT ===
504926

```

Figura 6 – Verifikimi i strukturës dhe numrit të rreshtave të dataset-it.

III.4.4. Statistikat Përshkruese

Funksioni describe() u përdor për të gjeneruar statistika përshkruese mbi dataset-in. Rezultatet ofrojnë informacion mbi vlerat minimale, maksimale dhe mesataret e kolonave numerike.


```

10:46 PM (1s) 22 Python
print("=== SUMMARY STATISTICS ===")
big_df.describe().show()

(2) Spark Jobs

=== SUMMARY STATISTICS ===
+-----+-----+-----+-----+-----+-----+-----+-----+
|summary|  Year|Country|Energy Product Name|Flow Breakdown|Unit Of Measure|      Value|  Assessment Code|
+-----+-----+-----+-----+-----+-----+-----+-----+
|  count| 504926| 504926|          504926|          504926|          504926|    504926|          504926|
|   mean|   NULL|   NULL|          NULL|          NULL|          NULL| 5499.345397109477| 2.547502010195534|
|  stddev|   NULL|   NULL|          NULL|          NULL|          NULL| 25372.627623533208| 0.8289319131401508|
|   min|1/1/2002|Algeria|      Crude Oil|Closing stocks|      CONVBL|         0.0|         1|
|   max|9/1/2024|  Yemen| Total oil products| Stock changes|      KTONS|    1204561.0|         3|
+-----+-----+-----+-----+-----+-----+-----+-----+

```

Figura 7 – Statistikat përshkruese të dataset-it.

III.4.5 Agregimi i të Dhënave

Grupimi sipas vendeve

Të dhënat u grupuan sipas kolonës Country dhe u llogarit totali i vlerave të energjisë për secilin vend.

```

10:46 PM (1s) 24
country_stats = big_df.groupBy("Country") \
    .agg(_sum("Value").alias("Total_Energy")) \
    .orderBy(col("Total_Energy").desc())

country_stats.show(10)

(2) Spark Jobs

> country_stats: pyspark.sql.connect.dataframe.DataFrame = [Country: string, Total_Energy: double]
+-----+-----+
|  Country|  Total_Energy|
+-----+-----+
|United States| 6.266370708778055E8|
| Saudi Arabia|3.5438467041975063E8|
|      China|2.0229227545453855E8|
|    Russia| 1.768312802803137E8|
|    Mexico| 1.54347305451489E8|
|    Canada|1.2877878222270088E8|
|    Norway|1.2234416597362146E8|
|     India|1.2091987380665836E8|
|    Kuwait|1.1379648238120772E8|
|     Qatar| 9.757494554229662E7|
+-----+-----+
only showing top 10 rows

```

Figura 8 – Top vendet sipas totalit të energjisë.

Grupimi sipas produkteve energjetike

Të dhënat u grupuan sipas kolonës Energy Product Name për të identifikuar produktet me vlerat më të larta totale.

```
product_stats = big_df.groupBy("Energy Product Name") \
    .agg(_sum("Value").alias("Total_Value")) \
    .orderBy(col("Total_Value").desc())

product_stats.show(10)
```

▶ (2) Spark Jobs

```
> product_stats: pyspark.sql.connect.dataframe.DataFrame = [Energy Product Name: string, Total_Value: double]
```

Energy Product Name	Total_Value
Crude Oil	5.665313430713375E8
Total oil products	4.2218352206985795E8
Total	3.9199660227875775E8
Motor and aviatio...	2.2298110078838202E8
Gas/diesel oil	2.0211959308492088E8
Liquefied petrole...	2.0011054527619204E8
Other oil products	1.4012685395029017E8
Kerosenes	1.3279932843123569E8
Fuel Oil	1.3106599270022148E8
NGL	1.1727403868211538E8

only showing top 10 rows

Figura 9 – Top produktet energjetike sipas vlerës totale.

III.4.6 SparkSQL Analysis

Për validimin e rezultateve u përdor SparkSQL. Query-ja llogarit totalin e energjisë sipas vendeve dhe rendit rezultatet në mënyrë zbritëse.

Rezultatet e marra janë të njëjta me ato të analizës së realizuar përmes DataFrame API, duke konfirmuar korrektësinë e përpunimit të të dhënave.

```
big_df.createOrReplaceTempView("energy")

sql_result = spark.sql("""
SELECT Country,
       SUM(Value) AS Total_Energy
FROM energy
GROUP BY Country
ORDER BY Total_Energy DESC
LIMIT 10
""")

sql_result.show()
```

▶ (2) Spark Jobs

> sql_result: pyspark.sql.connect.dataframe.DataFrame = [Country: string, Total_Energy: double]


Country	Total_Energy
United States	6.266370708778055E8
Saudi Arabia	3.5438467041975063E8
China	2.0229227545453855E8
Russia	1.768312802803137E8
Mexico	1.54347305451489E8
Canada	1.2877878222270088E8
Norway	1.2234416597362146E8
India	1.2091987380665836E8
Kuwait	1.1379648238120772E8
Qatar	9.757494554229662E7

Figura 10 – Query SparkSQL dhe rezultati i ekzekutimit.


III.5 Network Analysis

III.5.1. Vizualizimi i Rrjetit Social (Social Network Visualization)

Figura paraqet një rrjet bipartit të industrisë së naftës, ku nyjet përfaqësojnë vendet dhe produktet e naftës, ndërsa lidhjet tregojnë marrëdhëniet ndërmjet tyre. Nga vizualizimi vërehet se produkte si Crude Oil, Total Oil Products dhe Fuel Oil zënë pozita qendrore dhe kanë numër të madh lidhjesh. Gjithashtu, vende si Saudi Arabia, United States dhe China lidhen me shumë produkte, duke reflektuar rëndësinë e tyre në rrjet. Ky vizualizim shërben si bazë për analizën e metrikave Degree Centrality, Betweenness Centrality dhe Closeness Centrality.



III.5.2. Degree Centrality



Formula: $C_D(v) = \frac{deg(v)}{n-1}$, ku:

- $deg(v)$ = numri i lidhjeve direkte të nyjës
- n = numri total i nyjeve në rrjet

Vlerat e llogaritura


Nyjet me Degree Centrality më të lartë:

Nyja	Degree Centrality
Crude Oil	0.625
Fuel Oil	0.625
Gas/Diesel Oil	0.625

Interpretimi

Nyjet me Degree Centrality më të lartë janë produktet kryesore të naftës, të cilat lidhen me shumicën e vendeve në rrjet. Kjo tregon se këto produkte kanë rëndësi të madhe në strukturën e rrjetit dhe shërbejnë si pika qendrore të lidhjes ndërmjet vendeve prodhuese. Nga ana tjetër, vende si China, Syria dhe Russia kanë më pak lidhje direkte me produktet e përfshira në dataset dhe për këtë arsye paraqesin vlera më të ulëta të Degree Centrality.

III.5.3. Betweenness Centrality



$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

Formula: , ku:

- σ_{st} është numri i rrugëve më të shkurtra ndërmjet s dhe t
- $\sigma_{st}(v)$ është numri i këtyre rrugëve që kalojnë nëpër v

Vlerat e llogaritura


Top 3 nyjet me Betweenness Centrality më të lartë

Rank	Nyja	Betweenness Centrality
1	Crude Oil*	0.032663398
2	Fuel Oil*	0.032663398
3	Gas/Diesel Oil*	0.032663398

Interpretimi

Nyjet me Betweenness Centrality më të lartë veprojnë si ura lidhëse ndërmjet pjesëve të ndryshme të rrjetit. Këto nyje luajnë rol të rëndësishëm në rrjedhën e informacionit dhe lidhjen ndërmjet vendeve dhe produkteve të naftës. Heqja e tyre do të ndikonte ndjeshëm në strukturën dhe lidhshmërinë e rrjetit.

III.5.3. Closeness Centrality



$$C_C(v) = \frac{n-1}{\sum_{u \neq v} d(v,u)}$$

Formula: , ku

- $d(v,u)$ është distanca më e shkurtër ndërmjet nyjeve v dhe u
- n është numri total i nyjeve në rrjet

Vlerat e llogaritura

Top 3 nyjet me Closeness Centrality më të lartë

Nyja	Closeness Centrality
Crude Oil	0.727272727
Gas/Diesel Oil	0.727272727
Fuel Oil	0.727272727

Interpretimi

Nyjet me Closeness Centrality më të lartë janë më afër mesatarisht me të gjitha nyjet e tjera në rrjet. Kjo do të thotë se ato mund të arrijnë ose të ndikojnë nyjet e tjera me më pak hapa krahasuar me nyjet e tjera. Në rrjetin tonë, produktet kryesore të naftës si **Crude Oil**, **Gas/Diesel Oil** dhe **Fuel Oil** janë të pozicionuara në qendër të rrjetit dhe kanë qasje më të shpejtë ndaj pjesës më të madhe të nyjeve.

IV. Konkluzione

Ky projekt demonstroi përdorimin e teknologjive moderne të Big Data për migrimin, procesimin dhe analizën e të dhënave në sisteme relacionale, NoSQL dhe platforma të shpërndara. Përmes MongoDB, Apache Spark dhe analizës së grafeve u treguan avantazhet e fleksibilitetit, scalability dhe performancës në trajtimin e volumeve të mëdha të të dhënave.